「제7회 대구 빅데이터 분석 경진대회」
분석 결과 보고서

접수번호	※ 작성하지 않음

성명(팀명)	백운중(애플살껄)
분석과제명	대구시 소방차 출동로 취약지역 분석 기반 맞춤형 서비스 제안 - 머신러닝 기반 예측

Ⅰ. 분석개요

▢ 분석목적

본 분석의 목적은 대구시 읍면동 단위에서 화재 출동 도착시간과 출동횟수를 머신러닝 회귀모델을 활용하여 정밀 예측하고, 그 결과를 SHAP 기반 중요 요인 도출, 위험성 지도화(출동횟수·도착시간을 가중 결합한 위험도 점수), 정책 시뮬레이션과 하나의 파이프라인으로 연결하여 지역별 출동로 개선의 우선순위와 기대효과를 정량화하는 데 있습니다. 단순 현황 나열을 넘어 어디를 먼저, 무엇으로 개선하면 얼마나 빨라지는가를 수치로 제시해 의사결정의 정확도를 높이고자 합니다.

이를 위해, 첫째 예측 단계에서 시간·요일·월 특성을 반영한 읍면동별 도착시간·출동횟수 추정치를 산출합니다. 둘째 설명 단계에서 SHAP을 활용해 도로인프라 요인, 주차장 확보율, 인구, 면적, 차량 속도·통행량 등 영향 요인의 기여도를 정량적으로 해석합니다. 셋째 시각화 단계에서는 출동횟수와 도착시간을 정책목표에 맞는 가중치로 결합하여 5등급 위험성 지도로 시각화함으로써 맞춤 대응 우선순위를 직관적으로 제시합니다. 넷째 시뮬레이션 단계에서는 특정 동의 개입 가능한 변수(예: 4m 이하 도로폭을 4~5.5m로 확장, 주차장 확보율 증가 등)만 변경하여 도착시간 변화를 추정할 수 있도록 합니다.

최종적으로 머신러닝 예측 + SHAP 해석 + 위험성 지도 + 정책 시뮬레이

션을 유기적으로 결합하여, 대구시 소방차 출동로 개선정책의 우선순위 선정과 자원 배분을 객관적 수치로 뒷받침하고, 현장 적용을 신속하게 검토·보완할 수 있는 근거를 제공하는 것이 목표입니다.

▢ 배경 및 필요성

※ 대구시의 시군구별 화재 출동 거리 차이

시군구별 화재 출동 평균 거리(2024년)

※대구시의 요일별 화재 출동 도착 시간 차이

요일별 화재 출동 도착시간(2024년)

※ 대구시의 월별 화재 출동 빈도수 차이

월별 화재 출동 빈도수(2024년)

※ 대구시의 시간별 화재 출동 데이터 차이

대구시는 지역별로 인구, 면적, 소방서 접근성, 도로여건, 주차밀집, 교통 혼잡 등 물리·교통 여건이 크게 달라 읍면동별 출동 지연의 양상과 원인이 상이합니다. 또한 동일한 화재 유형이라도 시간·요일·월에 따라 혼잡도가 달라 도착시간·출동횟수의 변동성이 커집니다. 한정된 예산과 공사 여건 속에서 모든 지역을 동시에 개선하기는 어렵기 때문에, 어디를 먼저, 어떻게 개선할지에 대한 정밀한 우선순위 결정이 필수적입니다.

기존의 현황 점검·경험 중심 판단은 어떤 요인이 얼마나 영향을 미치는지와 개선 대안 적용 시 기대되는 변화(출동시간이 얼마나 단축되는지 등)을 동일 기준으로 정량 비교하기 어렵습니다. 특히 도로폭·전체 도로길이·주차장 확보율·평균 속도·통행량 등 복합 요인의 기여도를 설명하지 못하면, 지역·시간대 간 비교 가능성이 떨어지고 우선순위의 설득력

도 약해집니다.
따라서 본 분석에서는 읍면동별 시간·요일·월 수준에서 출동 도착시간·출동횟수의 규모를 정량화하고, 다양한 도로·교통·주차 등 다양한 요인의 영향을 SHAP로 설명 가능하게 제시하며, 시뮬레이션에서 개선 정책으로 변경 가능한 변수만 변경했을 때의 전후 변화를 수치로 제시할것입니다. 이처럼 수치로 명확히 제시하고, 위험지도와 중요요인 시각화로 한눈에 이해 가능하게 함으로써 결과의 설득력을 높입니다. 그 결과, 효율이 큰 조치부터 우선 적용할 수 있고, 신뢰 가능한 개선 정책 결정이 가능해질 것이라고 생각합니다.

▢ 분석요약

○ 활용데이터 :

- 소방·구급·구조·생활안전 출동 이력(출동횟수/ 도착시간)
- 대구시 인구·면적·세대·전통시장 수 등 기초지표
- 도로 인프라(길이, 도로폭별 길이)
- 교통정보(통행량·평균속도)

○ 분석도구 : Python(NumPy, Pandas), scikit-learn, XGBoost, Optuna, SHAP, Matplotlib/Geo, Joblib

○ 분석기법 :

- 머신러닝 회귀 예측(XGBRegressor, log1p 타깃 변환, K-Fold OoF 검증)
- SHAP 로 중요요인 도출
- 위험도 점수 산출(출동횟수·도착시간 가중 결합) 및 시각화(위험도 점수 기반 5등급 지도화)
- 정책 시뮬레이션: 시뮬레이션을 적용하고자 하는 지역의 개입 변수만 수정해 전/후 차이 산출

○ 분석결과

- 읍면동별 시간/요일/월 단위 도착시간·출동횟수 예측치 산출
- 동별 SHAP 중요요인 산출
- 위험도 점수 기반의 5등급 위험지도로 고위험 동을 직관적으로 제시
- 시뮬레이션으로 개선 정책 적용 시 도착시간 단축 효과 수치 제시

○ 활용방안 :

- 위험지도·SHAP·시뮬레이션 결과를 바탕으로 정확도 있는 개선정책 수립 및 집행 우선순위 결정 가능
- 동일 파이프라인을 구급·구조·생활안전 등 의 데이터에도 적용 가능 (핵심 변수 및 하이퍼파라미터만 해당 업무에 맞게 변경하면 모델·SHAP·위험지도·시뮬 절차를 그대로 재사용 가능)

▢ 독창성 및 차별성

기존 분석들은 전역 평균 지표나 단순 상관 지도에 머물러 '어디가 문제인지'만 보여주는 경향이 많았습니다. 반면 본 과제는 예측-설명-지도-정책 시뮬레이션을 한 체계로 연결해 '왜 문제인지(요인·영향성)'와 '무엇을 바꾸면 얼마나 나아지는지(분·초·% 정량적 개선 효과)'를 동시에 제시합니다. 또한 모델·코드·산출을 함께 제공해 재현·운영 연계·타 영역 확장까지 고려한 점에서, 일회성 보고가 아닌 지속적이고 실행 가능한 의사결정 시스템이라는 점이 본질적 차이입니다.

1) 지역별 맞춤 해석

지역별 SHAP 테이블·그래프로 요인의 영향력을 정밀 파악합니다. 같은 위험성 등급이라도 지역마다 개선 방향이 달라질 수 있음을 수치로 확인하여 지역 맞춤형 개선안을 도출합니다.

2) 위험도 점수 + 지도 시각화

출동횟수와 도착시간을 정책목표에 맞춰 가중 결합하고 5등급 위험지도로 표현하여 공간적 우선순위를 명확히 제시합니다. 정량 수치 + 요인

설명(SHAP) + 지도 시각화의 결합으로 설득력과 해석 용이성을 동시에 확보합니다.

3) 정책 시뮬레이션

개입 가능한 변수만 선택적으로 변경해 전·후 도착시간 변화를 분·초·% 단위로 산출합니다. 단순 중요도 제시를 넘어 대안 간 효과 크기를 사전에 수치 비교하여 정책 집행 효율을 극대화합니다.

4) 재현성·운영 연계·확장성

학습 파이프라인, 예측 결과, SHAP 표, 시뮬레이션 코드를 함께 제공해 동일 조건 재현이 가능합니다. 또한 환경 버전과 하이퍼파라미터, 전처리(One-Hot, log1p/expm1)까지 코드화하여 실행 편차를 최소화했습니다. 동일 알고리즘을 알맞게 변환하면 구급·구조·생활안전으로 신속 확장할 수 있으며, 변수와 하이퍼파라미터만 각 업무 지표에 맞춰 변경하면 됩니다.

Ⅱ. 분석방법

▢ 활용데이터

데이터명	형식	대상기간	사용변수	출처	비고
교통정보 및 교통량	csv	2017.01 ~ 2018.12	차량 통행량, 평균속도	한국교통연구원	대구 데이터분석 활용센터
구급 출동 일지 데이터	csv	2021.01 ~ 2024.12	출동 출발시간, 출동 도착시간	대구광역시 소방안전본부	대구 데이터분석 활용센터
구조 출동 일지 데이터	csv	2022.01 ~ 2024.12	출동 출발시간, 출동 도착시간	대구광역시 소방안전본부	대구 데이터분석 활용센터
생활안전 출동 일지 데이터	csv	2023.01 ~ 2024.12	출동 출발시간, 출동 도착시간	대구광역시 소방안전본부	대구 데이터분석 활용센터
화재 출동 일지 데이터	csv	2021.01 ~ 2024.12	출동 출발시간, 출동 도착시간	대구광역시 소방안전본부	대구 데이터분석 활용센터
행정구역 지리정보	shp	2023.04	읍면동 행정경계	국토교통부	대구 데이터분석 활용센터
주민등록 인구 현황	csv	2023	인구수	통계지리 정보서비스	https://sgis.kostat.go.kr/view/thematicMap/categoryList
자가주차장 확보율	shp	2020	자가주차장 확보율	통계지리 정보서비스	https://sgis.kostat.go.kr/view/thematicMap/categoryList
전통시장 현황	shp	2024	전통시장 수	통계지리 정보서비스	https://sgis.kostat.go.kr/view/thematicMap/categoryList
읍면동별 면적	csv	2025.06	면적	대구광역시청	https://www.daegu.go.kr/index.do?menu_id=00000253
실폭도로 대구	shp	2025.09	도로폭별 도로길이	브이월드	https://www.vworld.kr/dtmk/dtmk_ntads_s001.do

▢ 분석방법

1) 분석도구(툴)

개발·실행 환경은 Python을 사용하였습니다. 핵심 라이브러리는 NumPy, Pandas, scikit-learn 1.3.2, XGBoost 2.0.3, Optuna, SHAP, Matplotlib, Joblib 등을 사용하였습니다.

2) 데이터 전처리 내용 및 검증 여부

2-1) 데이터셋과 키 결합

기초지표(대구통합정보)는 인구, 면적, 세대, 인구밀도, 주차장 확보율, 전통시장 수, 도로 인프라(전체 길이·도로폭 구간별 길이·비율), 교통(일일차량 통행량·평균속도) 등을 포함합니다. 소방 출동 데이터(화재_시간·화재_요일·화재_월)는 동별로 시간/요일/월 단위의 출동횟수(count_)와 도착시간(time_)을 포함합니다. 인코딩 및 특수문자 오류를 없애기 위해 한글 컬럼을 영문으로 매핑한 뒤 동을 기준으로 병합하되, 중복 컬럼을 제거하여 정합성을 확보하였습니다.

2-2) 이상치 및 필터링

도착시간이 60분 이상인 출동데이터는 이례적인 상황 및 이상 데이터일 가능성이 높으므로 학습·분석에서 제외하였습니다.

2-3) 결측치 대치

일일차량 통행량(traffic)는 인구 규모에 비례하는 경향이 커서 해당 피처의 결측치는 같은 시군구의 인구수 가중평균으로 대치하였습니다.

일일차량 평균속도(speed)는 인구밀도와 음의 상관관계가 있으므로 같은 시군구의 인구밀도 역수의 가중평균으로 대치하였습니다.

도로 길이 계열(도로폭별 길이)는 면적에 양의 상관관계가 있으므로 해당 피처의 결측치는 같은 시군구의 면적 가중평균으로 대치하였습니다.

2-4) 범주·수치 전처리

읍면동은 LabelEncoder로 dong_le를 생성하여 학습 입력으로 사용하였습

니다. 그외의 범주형 피처는 OneHotEncoder(handle_unknown='ignor 로 변환하고 수치형은 그대로 전달하였습니다. 시간 변수는 day를 정수(월=0 … 일=6)로 인코딩하고 hour와 month는 정수 그대로 사용하였습니다.

2-5) 타깃 라벨 변환

count와 time은 분포의 웨도가 커서 안정적 학습이 어렵다고 판단하여 log1p 변환으로 학습하고 예측 시 expm1으로 복원하였습니다. 복원 후에는 음수값을 0으로 클립하여 안정적 RMSE와 해석 가능성을 확보하였습니다.

2-6) 정합성·무결성 검증

도로 길이 관련 모든 변수의 단위를 km로 통일하였습니다. 예측 및 시뮬레이션 입력은 학습 당시 피처 목록과 순서와 동일하게 정렬하여 차원 불일치를 방지하였습니다. 교차검증 분할 전후로 전처리 파이프라인의 fit과 transform을 분리하여 데이터 누수를 차단하였습니다.

3) 분석기법 및 분석절차

3-1) 데이터 구축

세가지 데이터셋을 구축하였습니다.

시간 단위 데이터셋(fire_time_merged)은 count_hour와 time_hour, 요일 단위 데이터셋(fire_day_merged)은 count_day와 time_day, 월 단위 데이터셋(fire_month_merged)은 count_month와 time_month를 타깃으로 설정하였습니다. 대구통합정보의 공통 피처는 동일하게 사용하되, 각 데이터셋에 해당 차원(시간·요일·월)의 식별 변수와 타깃을 별도 컬럼으로 포함하여 데이터셋별로 독립 학습하도록 구성하였습니다.

3-2) 학습 및 교차검증

알고리즘은 XGBRegressor(tree_method="hist")를 사용하였습니다. KFold(n_splits=5, shuffle=True, random_state=42)로 OOF 예측을 저장하고 RMSE를 핵심 지표로 평가하였습니다. run_cv_regression 파이프라인으로 타깃 log1p 학습, 예측 expm1 복원, 0 하한 클립을 일관 처리하

였습니다. 각 fold의 모델 성능을 로깅하였고, 최종 모델은 전체 학습 데이터로 재학습하여 model_fire__.joblib으로 저장하였습니다. Optuna 기반의 하이퍼파라미터 탐색(tune_params)으로 n_estimators, max_depth, learning_rate, subsample, colsample_bytree, min_child_weight, reg_alpha, reg_lambda를 데이터셋·타깃별로 최적화하였습니다.

3-4) SHAP 산출

설명가능성(SHAP) 분석을 수행하였습니다. Tree SHAP으로 전역 및 동별 mean_abs_shap을 산출하였습니다(per_dong_feature_importance_shap). OneHot 확장 컬럼을 원 피처명으로 복원하여 동별 중요 영향요인을 생성하였습니다.

3-5) 위험도 점수 산출

위험도 점수는 w_1·MinMax(출동횟수) + w_2·MinMax(도착시간)으로 정의하였습니다. 기본값은 w_1=0.6, w_2=0.4로 두었으며 정책 목표에 따라 조정 가능하게 설계하였습니다.

3-6) 정책 시뮬레이션

개입 가능한 변수만 변경하여 전후 도착시간 변화(분·초·%)를 정량 비교하였습니다. 절차는 다음과 같이 정리하였습니다.

첫째, 학습 단계에서 사용한 피처 목록과 순서를 불러와 예측 입력 차원 및 순서를 동일하게 맞추었습니다.

둘째, 시뮬레이션을 적용할 동을 지정하고, 정책 변수(예: road_len_4, road_len_5.5, ratio_road_len_4, parking, speed 등)의 변경값을 편집하였습니다.

셋째, 학습 시 저장한 전처리+모델 파이프라인을 로드한 뒤, 기준 시나리오(변경 전)와 정책 시나리오(변경 후)에 대해 각각 예측을 수행하였습니다.

넷째, 두 시나리오의 결과를 비교하여 절대 차이(diff)와 상대 변화율(pct_change, %)을 산출하였습니다.

4) 분석결과 검증방법

분석검증은 K-Fold 5-fold OOF 체계로 수행하였습니다. 각 폴드에서 학습·검증을 분리하고 검증 세트에 대해서만 예측을 생성·누적하여 학습에 사용되지 않은 전 구간 OOF 예측값을 확보하였습니다. 평가는 RMSE를 중심으로 폴드별 점수를 평균±표준편차로 요약하였고, 전체 OOF 기준 RMSE을 보고하여 일반화 성능을 안정적으로 추정하였습니다.

Ⅲ. 분석결과

1) 검증 수행 결과(OOF 및 파라미터 튜닝)

검증은 K-Fold 5-fold OOF 체계로 수행하였습니다. 각 폴드에서 학습·검증을 분리하고, 검증 세트에 대해서만 예측을 생성·누적하여 학습에 사용되지 않은 전 구간 OOF 예측값을 확보하였습니다. 평가는 RMSE를 중심으로 폴드별 점수를 평균±표준편차로 요약하였고, 최종 보고는 전체 OOF 기준 RMSE로 정리하였습니다. 모든 결과는 Optuna 하이퍼파라미터 튜닝값(Best Params)을 적용하여 산출하였습니다.

1-1) 시간별 모델(fire_time)

출동횟수 RMSE=0.5374, 도착시간 RMSE=1.7827

동·시간 단위의 패턴이 가장 뚜렷하여 오차가 가장 낮게 나타났습니다. 특히 출동횟수는 소규모 변동까지 포착하여 세밀한 시간대 운영 판단에 유효하였습니다. 도착시간은 교통·협소도로 등 외생 변동이 있어 횟수 대비 RMSE가 상대적으로 컸지만, 분 단위 의사결정에 사용할 수 있는 수준의 정확도를 보였습니다.

1-2) 요일별 모델(fire_day)

출동횟수 RMSE=0.9906, 도착시간 RMSE=2.0419

요일 고유의 혼잡·활동 패턴이 반영되어 일관된 예측력을 보였습니다. 시간별 모델 대비 세밀도는 낮지만, 요일별 계획에 적합한 해상도를 확보하였습니다.

1-3) 월별 모델(fire_month)
출동횟수 RMSE=0.8082, 도착시간 RMSE=2.1360
계절성·행사 등 장기 요인이 작용하여 변동성이 상대적으로 커졌음에도, 튜닝을 통해 안정적인 월간 수준 예측을 확보하였습니다. 중·장기 출동로 보강 계획 수립에 활용 가능할것이라고 생각됩니다.

종합하면, 시간별 모델이 가장 낮은 RMSE로 미시적 의사결정에 적합하였고, 요일·월별 모델은 운영·전략 수준의 계획 수립에 유용하였습니다. 모든 모델에서 도착시간 예측의 RMSE가 출동횟수 대비 크게 나타났는데, 이는 도착시간이 도로 상황·일시적 장애 등 비정형 외생요인의 영향을 더 크게 받기 때문으로 생각됩니다.

2) 시각화 결과와 주요 인사이트
2-1) 피처 중요도 시각화(SHAP) 결과
※ 동별 예측에 대한 SHAP 상위 요인 표 및 차트예시(대명9동)

[대명9동] 상위 10 피처

	feature	mean_abs_shap
0	sigungu	0.271277
25	fire_count	0.210014
19	ambulance_count	0.097189
16	road_len	0.077318
13	road_len_8	0.063307
10	speed	0.042792
7	parking	0.041568
4	household	0.038356
26	month	0.035917
18	ambulance_len	0.035187

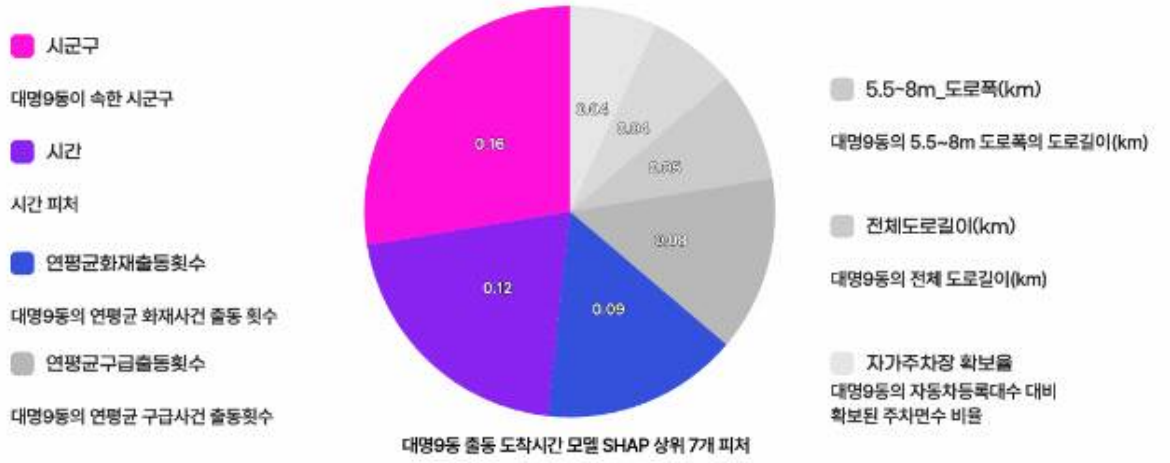

동별 예측값에 기여한 요인을 SHAP으로 해석하여 파이차트·표 형태로 정리하였습니다. 예시 사진은 대명9동 모델의 상위 요인을 시각화한 것으로, 시간·도로 인프라·주차 관련 변수가 혼합되어 기여하였음을 확인할 수 있었습니다. 본 분석은 동별 SHAP 표를 기본 산출하였으며, 행정동마다 상위 요인의 구성 및 기여도가 상이하여 동일 등급의 지역이라도 개선 처방이 동마다 달라져야 함을 시사하였습니다.

2-2) 위험도 지도 결과

※ 위험도 5등급 지도 예시(대구 남구 1월)

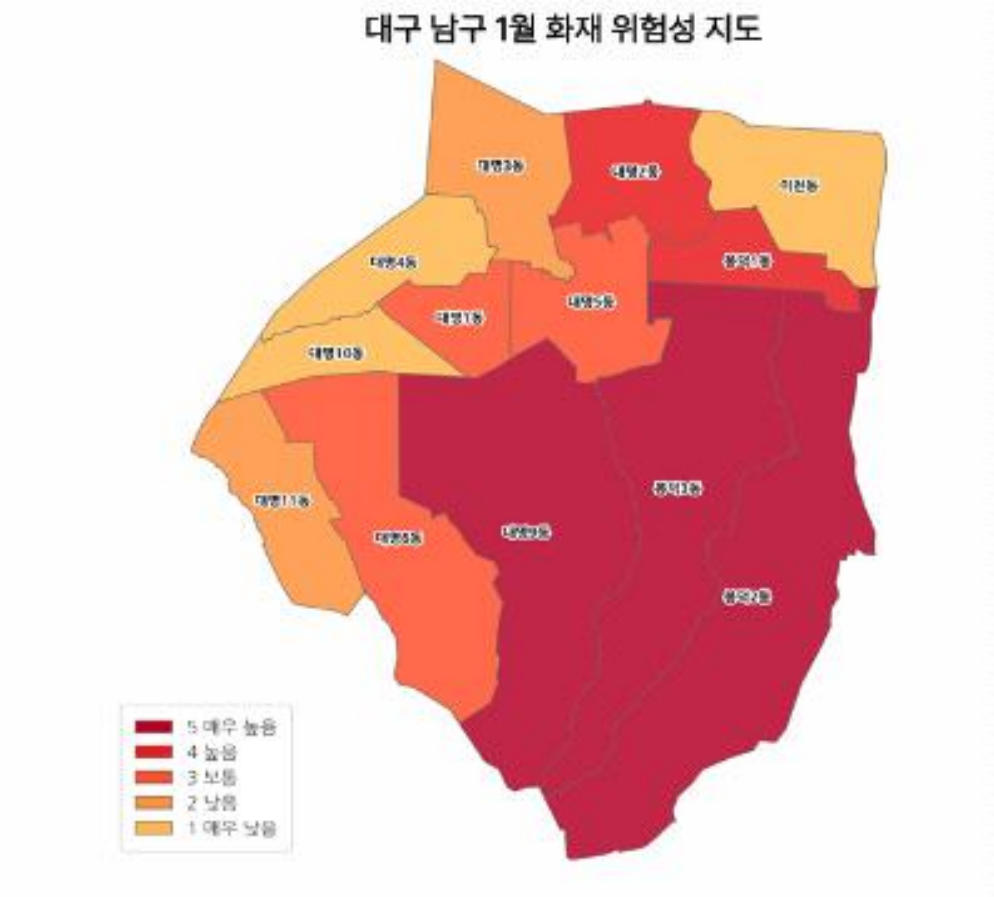

출동횟수와 도착시간을 가중 결합(0.6/0.4) 하여 5등급 위험도 지도로 표현하였습니다. 1월 기준 남구 예시사진에서는 중심부와 동남부 일부가 상대적으로 진하게(위험도 높음) 나타났고, 북서부 외곽은 상대적으로 옅게 분포하였습니다.

3) 정책 시뮬레이션 결과

※ 정책 시뮬레이션 예시(다사읍의 도로폭 4m 이하 도로 20km를 4~5.5m로 확장 시)

```
# 모델
MODEL_TIME = f"{SAVE_DIR}/model_fire_time_time_hour.joblib"
MODEL_COUNT = f"{SAVE_DIR}/model_fire_time_count_hour.joblib"
# 원천 데이터
DAEGU_INFO_CSV = "/content/drive/MyDrive/대구빅데이터분석/대구통합정보.csv"
FIRE_TIME_CSV = "/content/drive/MyDrive/대구빅데이터분석/화재/화재_시간.csv"
# 시뮬레이션 대상
DONG_NAME = "다사읍"
# 바꾸고 싶은 값 지정
EDIT_VALUES = {
"road_len_4": 10.40206311, # 예: 4m 미만 도로길이(km)
"road_len_5.5": 34.22991378, # 예: 4~5.5m 도로길이(km)
"ratio_road_len_4": 0.0690190187, # 예: 4m 미만 도로 비율(0~1)}
TARGETS = ["count_hour", "time_hour"] # fire_time 타깃

[다사읍 도로 피처 시뮬레이션 저장]
- 적용 EDIT_VALUES: {'road_len_4': 10.40206311, 'road_len_5.5': 34.22991378,
'ratio_road_len_4': 0.0690190187}
- 학습 피처 개수: 28 (fire_time_pred.csv 기준)
[요약 평균]
pred_time_hour_base pred_time_hour_mod diff_time_hour_mod \
mean 1.5712 1.325 -0.2463

pct_change_%_time_hour_mod pred_count_hour_base pred_count_hour_mod \
mean -24.784401 1.0141 1.0444

diff_count_hour_mod pct_change_%_count_hour_mod
mean 0.0303 4.1217
```

학습 피처 셋과 동일한 입력 구조를 유지한 채 개입 가능한 변수만 수정하여, 전·후 도착시간 변화를 정량 추정하였습니다. 예시사진에서는 다사읍에서 4m 이하 도로 20km를 4~5.5m로 확장한다는 가정 하에, 평균 도착시간이 약 94.3초 → 79.5초로 단축(▲14.8초, 약 15.7% 개선)되는 결

과를 확인하였습니다.

Ⅳ. 활용방안

1) 중요 요인 진단

동별 예측값을 SHAP 기반으로 분해하여 어떤 요인이 도착시간·출동횟수에 얼마나, 어떤 방향으로 영향을 미치는지를 수치로 제시할 수 있습니다.

예를 들어 협소도로 비중, 평균속도, 주차장 확보율, 전체 도로길이 등 개입 가능한 변수의 기여도를 산출함으로써 "같은 위험 등급이라도 왜 위험한가"를 명확히 설명할 수 있습니다.

이 결과를 정책 의사결정에 활용하여 정량적 우선순위를 도출할 수 있습니다.

2) 위험도 지도 기반 맞춤 대응

출동횟수와 도착시간을 정책 목적에 맞는 가중치(기본 0.6/0.4) 로 결합한 위험도 점수를 동 단위 지도에 5등급으로 시각화함으로써 지역별 위험성을 한눈에 파악할 수 있습니다.

월·요일·시간 수준의 시나리오를 선택해 상황별 위험 분포를 비교할 수 있고, 동 중심 라벨과 범례를 표준화하여 실무 보고와 현장 관제 화면에 즉시 적용할 수 있습니다.

실제 업무 흐름에서는 등급 4–5 구역을 1차 후보군으로 추출한 뒤, 동별 SHAP 상위 요인과 결합하여 "어디를 먼저, 무엇으로" 대응할지 결정합니다. 더 나아가 예상 단축시간(초·%) 대 비용을 함께 보아 효율 순으로 사업을 정렬하면 예산 배분의 객관성과 설득력을 동시에 확보할 수 있습니다.

3) 정책 시뮬레이션(전·후 정량 비교)

학습 파이프라인과 동일한 입력 스키마를 사용하여 개입 가능한 변수만 수정하고, 변경 전·후의 예측 도착시간·출동횟수를 초·%로 정량 비교할 수 있습니다.

예를 들어 "4m 이하 도로 20km를 4~5.5m로 확장" 같은 가정에 대해 전후 단축 효과를 산출할 수 있어, 사업 착수 전 타당성 검토에 유용합니다.

4) 타 업무영역 확장(구급·구조·생활안전 등)

본 파이프라인의 알고리즘을 구급·구조·생활안전 등 다른 출동 영역 데이터로 신속히 확장할 수 있습니다. 각 영역의 목적에 영역 특화 피처를 변경 및 추가하여 활용하면 됩니다.

결과적으로 동일 프레임의 알고리즘으로 여러 분야의 우선순위 선정-정책 효과 추정-성과 검증을 일관되게 수행할 수 있습니다.

Ⅴ. 기타

1) 데이터활용센터 데이터 外 참고 데이터

- 주민등록 인구 현황(읍면동) · 형식: CSV · 기준연도: 2023 · 주요항목: 인구수 · 제공처: 통계지리정보서비스(KOSIS)

  링크: https://sgis.kostat.go.kr/view/thematicMa
- 자가주차장 확보율(읍면동) · 형식: SHP · 기준연도: 2020 · 주요항목: 자가주차장 확보율 · 제공처: 통계지리정보서비스(KOSIS)

  링크: https://sgis.kostat.go.kr/view/thematicMa
- 전통시장 수(읍면동) · 형식: SHP · 기준연도: 2024 · 주요항목: 전통시장 수 · 제공처: 통계지리정보서비스(KOSIS)

  링크: https://sgis.kostat.go.kr/view/thematicMa
- 읍면동별 면적 · 형식: CSV · 기준시점: 2025.06 · 주요항목: 면적(㎢) · 제공처: 대구광역시

  링크: https://www.daegu.go.kr/index.do?menu_id=
- 실폭도로(대구) · 형식: SHP · 기준시점: 2025.09(수집 시점 기준) · 주요항목: 도로폭별 도로길이 · 제공처: 브이월드

  링크: https://www.vworld.kr/dev/v4dv_k_road_s00

2) 참고 논문

- Lundberg, S. M., & Lee, S.-I., "A Unified Approach to Interpreting Model Predictions (SHAP)", *NeurIPS*, 2017. 〈설명가능성·SHAP 근거〉
- Akiba, T., et al., "Optuna: A Next-generation Hyperparameter Optimization Framework", *KDD*, 2019, pp. 2623-2631. 〈하이퍼파라미터

튜닝〉

- Hyndman, R. J., & Koehler, A. B., "Another look at measures of forecast accuracy", *International Journal of Forecasting*, 22(4), 2006, pp. 679-688. 〈RMSE 등 예측오차 지표〉
- Greco, S., Ishizaka, A., Tasiou, M., & Torrisi, G., "On the Methodological Framework of Composite Indicators", *Social Indicators Research*, 141, 2019, pp. 61-94. 〈가중합 기반 종합지수·위험도 점수〉
- Han, J., Kamber, M., & Pei, J., "Data Mining: Concepts and Techniques (3rd ed.)", Morgan Kaufmann, 2011. 〈정규화·Min-Max 스케일링 실무 기준〉